ESTUDO DIRIGIDO · ENCONTRO 3 DE 4 · M1 · IA NO DESENVOLVIMENTO: FERRAMENTAS, PROMPTING E CONTEXTO DE PROJETO

Prompts e contexto de projeto

Você vai explicar por que o modelo preenche lacunas e varia, especificar pedidos verificáveis e decidir o que vai no CLAUDE.md, medindo cada mudança no caso Vitrine.

Aula de 12/11/2026 | Tempo sugerido: cerca de 3 horas, em uma ou duas sentadas

IA para QA · CESAR School

Como usar este estudo

Primeiro leia os conceitos na ordem: cada um sai do anterior, como na aula. Depois faça as práticas, que repetem no seu computador o que o professor demonstrou, com o Claude Code (aba Code do Claude Desktop) e o caso Vitrine. No fim, confira a autoavaliação e as respostas das perguntas.

ANTES DE COMEÇAR

- [ ] Claude Desktop com login numa conta Pro ou superior. Teste: a aba **Code** responde.
- [ ] A pasta `caso-vitrine` do repositório da turma. Teste: ela tem `prompts/formulacoes/F1.md` a `F4.md` e `casos-de-teste/CT-US01.md`.
- [ ] Na aba Code, **Local** → **Open folder…** → `caso-vitrine`, com **Worktree** desligado e o **Sonnet 5.5** no seletor (Ctrl+Shift+I; Cmd+Shift+I no macOS). Teste: cada sessão nova mostra o Sonnet 5.5, e o que o agente grava aparece em `caso-vitrine/saidas/`.
- [ ] Memória automática desligada. Teste: `/memory`, numa sessão na pasta, mostra a memória automática desligada; se estiver ligada, desligue ali.
- [ ] Modo **Manual**: aprove só gravações em `saidas/`; rejeite comandos e edições de outros arquivos. Nenhuma prática usa terminal. Anote as fichas no seu `registro-e3.md`.

O mapa da aula

Pergunta da aula: **o que muda a saída: a formulação ou o contexto?**



Mapa da aula em cadeia: formular, com os conceitos 1 e 2, pedir e conferir; o laboratório 1 mede quatro pedidos, do F1 ao F4; o contexto, conceito 3, é o CLAUDE.md; o laboratório 2 mede o F1 com o CLAUDE.md; e a pergunta destacada: o que muda a saída, a formulação ou o contexto?

Conceito 1 de 5

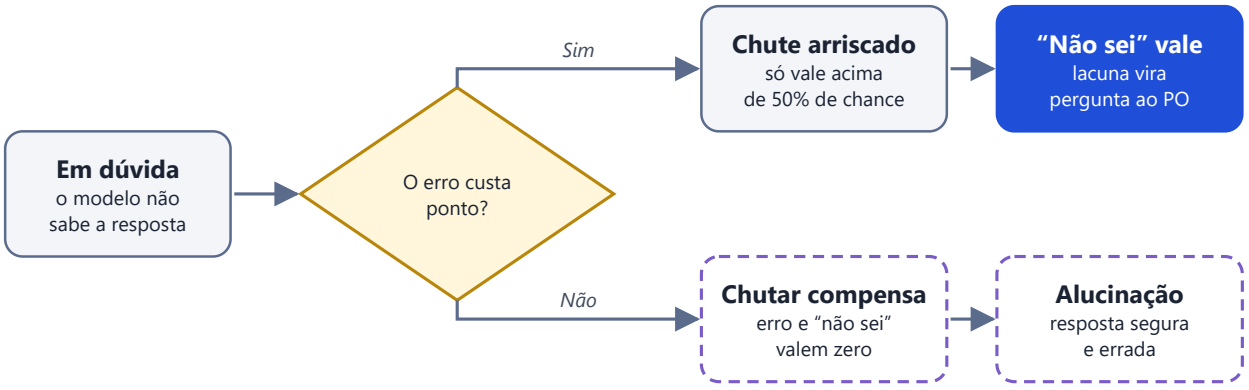
O modelo chuta porque a prova não desconta o erro

> **Numa avaliação que só soma acertos, errar e dizer “não sei” valem zero; nela, chutar é sempre a melhor estratégia, e o modelo aprende a chutar.**

Modelos de linguagem são comparados por avaliações, e a maioria funciona como uma prova que só soma acertos: o erro e o “não sei” valem zero. Em dúvida, chutar nunca baixa a nota. É o argumento de Kalai, Nachum, Vempala e Zhang em “Why Language Models Hallucinate” (setembro de 2025): a alucinação persiste, em boa parte, pela forma como as avaliações são pontuadas, e a proposta deles é mudar essa pontuação.

A pergunta do E1 mostra o mecanismo com uma conta. Se cada erro anulasse um acerto, um chute com chance p valeria p - (1 - p) = 2p - 1, positivo só acima de 50%. Aí o “não sei” vale mais que o chute incerto. A conta é da pergunta, não do artigo.

Para o QA: se o pedido não abre espaço para o “não sei”, o modelo preenche a lacuna. Abra esse espaço no pedido: quando a história não definir, registre como pergunta ao PO.



Decisão: o modelo está em dúvida e não sabe a resposta. O erro custa ponto? Se não, como nas avaliações que só somam acertos, chutar compensa, porque erro e “não sei” valem zero, e o resultado é a alucinação, uma resposta segura e errada. Se sim, o chute fica arriscado e só vale acima de 50% de chance de acertar; aí o “não sei” vale, e, para o QA, a lacuna vira pergunta ao PO.

NO CASO VITRINE

No ensaio de 12/11 (Sonnet 5.5, sem ferramentas, arquivos colados), um F1 marcou o parcelamento, que a US-02 não trata, como lacuna e, na mesma linha, escreveu: “O estorno cobre todas as parcelas”.

CONFUSÃO FREQUENTE

Achar que escrever “não suponha” no pedido acaba com o chute. Diminui o espaço do chute, mas não o elimina; a conferência continua.

PARA CONFERIR · RESPOSTA NO FIM

Se cada erro anulasse um acerto, a partir de que chance de acertar o chute compensa?

Conceito 2 de 5

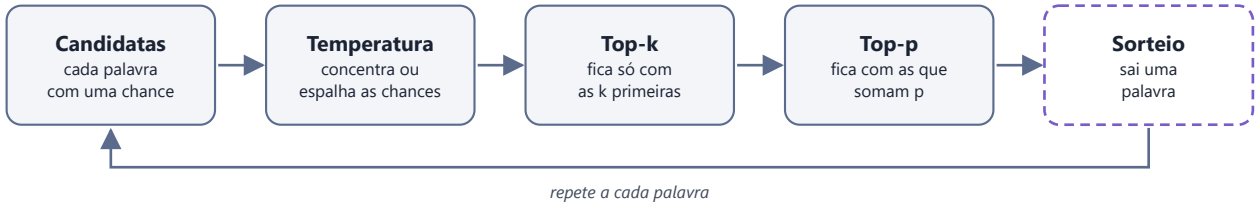
Temperatura, top-p e top-k regulam o sorteio da palavra

> **A cada palavra, o modelo dá uma chance a cada candidata e sorteia uma; temperatura, top-k e top-p mudam esse sorteio.**

O primeiro conceito explica a lacuna preenchida; este, por que a resposta muda de uma execução para outra. É o sorteio do E1 por dentro. A cada palavra, o modelo tem uma lista de candidatas, cada uma com uma chance. A temperatura baixa concentra a chance na mais provável; a alta espalha para as outras. O top-k corta a lista e fica só com as k candidatas mais prováveis. O top-p fica com as primeiras que, somadas, chegam a p, por exemplo 90%. O modelo sorteia uma, acrescenta ao texto e recomeça para a palavra seguinte.

Nos modelos Claude atuais, esses ajustes não estão nas suas mãos. Segundo o guia de migração da API da Anthropic para a versão 2026-10-21, os modelos a partir do Claude 4.7 já aceitavam só os valores padrão, e a versão nova da API retira os três parâmetros das requisições. O Claude Code não tem ajuste de temperatura.

Então “qual a temperatura ideal?” vira outra pergunta: como eu controlo a variação? Repetindo a execução nas mesmas condições e medindo. Para dizer que uma mudança no pedido fez diferença, a diferença entre pedidos precisa ser maior que a diferença entre duas execuções do mesmo pedido.



Ciclo da amostragem: cada próxima palavra candidata tem uma chance; a temperatura concentra ou espalha essas chances; o top-k mantém só as k mais prováveis; o top-p mantém as primeiras que, somadas, chegam a p; o sorteio escolhe uma palavra, e o ciclo se repete a cada palavra.

NO CASO VITRINE

No mesmo ensaio, o F1 deu 27 casos numa conversa e 24 na outra, e só a segunda acrescentou uma lista de prioridade. O F4 deu 11 e 10 casos, com 13 e 12 perguntas ao PO. Duas execuções por pedido mostram que há variação, não quanto ela vale em geral.

CONFUSÃO FREQUENTE

Rodar uma vez, gostar do resultado e concluir que o pedido funciona. Rode de novo, numa sessão nova, antes de comparar.

PARA CONFERIR · RESPOSTA NO FIM

No laboratório, por que o F1 e o F4 rodam duas vezes cada?

Conceito 3 de 5

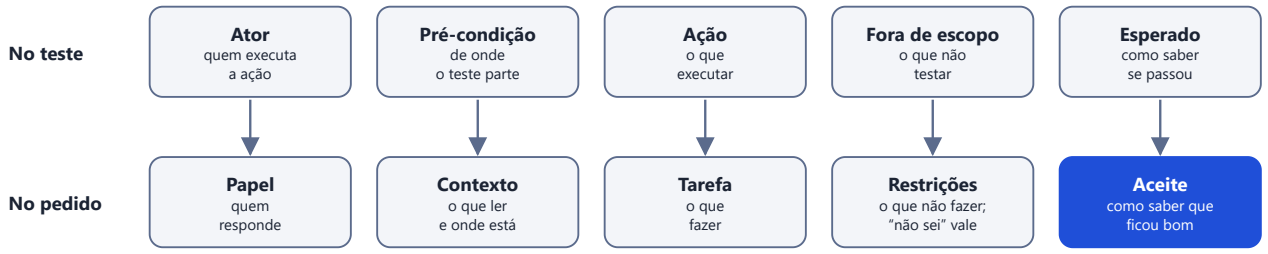
Formular um pedido é especificar, como num caso de teste

> **Formular é especificar o pedido como se especifica um caso de teste: papel, contexto, tarefa, restrições e critério de aceite.**

Os dois conceitos anteriores mostram onde o modelo completa sozinho: na lacuna sem “não sei” e no sorteio. Formular bem é fechar esses espaços. Um pedido especificado tem cinco partes, e cada uma corresponde a uma parte do caso de teste que você já escreve.

Papel diz quem responde, por exemplo um analista de QA da Vitrine. Contexto diz o que ele precisa saber e onde está: a história, o README. Tarefa diz o que fazer. Restrições dizem o que não fazer e os limites: usar só as regras escritas, registrar lacuna como pergunta ao PO, no máximo 12 casos. Critério de aceite diz como saber que a resposta ficou boa: cada regra coberta, cada caso apontando a origem.

A restrição “quando a história não definir, registre como PERGUNTA AO PO” é a opção do “não sei” do primeiro conceito, escrita no pedido. No caso Vitrine, o F1 tem só a tarefa; o F2 é o F1 com as cinco partes.



Cinco partes de um caso de teste e as cinco partes correspondentes de um pedido especificado: o ator, quem executa a ação, corresponde ao papel, quem responde; a pré-condição, de onde o teste parte, ao contexto, o que ler e onde está; a ação, o que executar, à tarefa, o que fazer; o fora de escopo, o que não testar, às restrições, o que não fazer, incluindo a permissão para o “não sei”; e o resultado esperado, como saber se passou, ao critério de aceite, como saber que a resposta ficou boa.

NO CASO VITRINE

No ensaio de 12/11, o F2 entregou 10 casos com a origem de cada um, uma tabela de rastreabilidade das oito regras e critérios e 11 perguntas ao PO. E mostrou por que a revisão continua: a primeira frase da resposta diz “Foram escritos 9 casos”, e a tabela tem 10.

CONFUSÃO FREQUENTE

Achar que pedido longo é pedido especificado. Texto a mais sem restrição nem critério de aceite não fecha nenhum espaço.

PARA CONFERIR · RESPOSTA NO FIM

Que parte do pedido especificado corresponde ao resultado esperado de um caso de teste?

Conceito 4 de 5

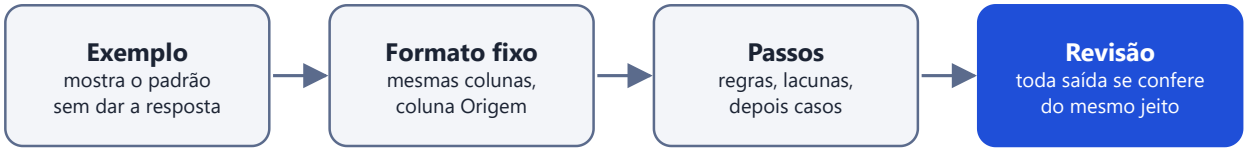
Exemplo, formato e passos tornam a saída verificável

> **Exemplo, formato fixo e passos não mudam o que o modelo sabe; mudam quão rápido você confere o que ele entregou.**

Especificar diz o que fazer. Este conceito, consequência do anterior, trata de como receber a resposta para conferir rápido. A revisão é o custo que sobra, e ela fica mais barata quando toda saída se confere do mesmo jeito.

Um exemplo de linha, tirado de outra história, mostra o padrão sem entregar a resposta. Um formato fixo, sempre com as mesmas colunas, põe a origem numa coluna que você confere contra a história. Passos pedem as regras, depois as lacunas e só então os casos; assim o raciocínio fica na tela, e você vê onde ele errou.

No caso Vitrine, o F3 é o F2 com exemplo e formato, e o F4 é o F3 com os três passos. Uma mudança por vez, como num experimento.



Três recursos levam a uma revisão comparável e mais barata: o exemplo mostra o padrão sem dar a resposta; o formato fixo dá as mesmas colunas em toda resposta, com uma coluna de origem; os passos pedem as regras, depois as lacunas, e só então os casos. Na chegada, toda saída se confere do mesmo jeito.

NO CASO VITRINE

No ensaio de 12/11, o F3 respondeu na tabela pedida, com as colunas ID, Pré-condição, Ação, Resultado esperado, Origem e Tipo, e a lista de perguntas ao PO depois. O F4 mostrou as regras, depois as lacunas e só então os casos; numa das execuções, para o motivo obrigatório, escreveu “Não definido: aguardando a PERGUNTA AO PO 3” em vez de inventar o resultado.

CONFUSÃO FREQUENTE

Julgar a saída pela aparência. Uma tabela bonita sem coluna de origem custa mais para revisar que uma lista simples com a origem em cada linha.

PARA CONFERIR · RESPOSTA NO FIM

Por que o exemplo de linha do F3 vem de outra história?

Conceito 5 de 5

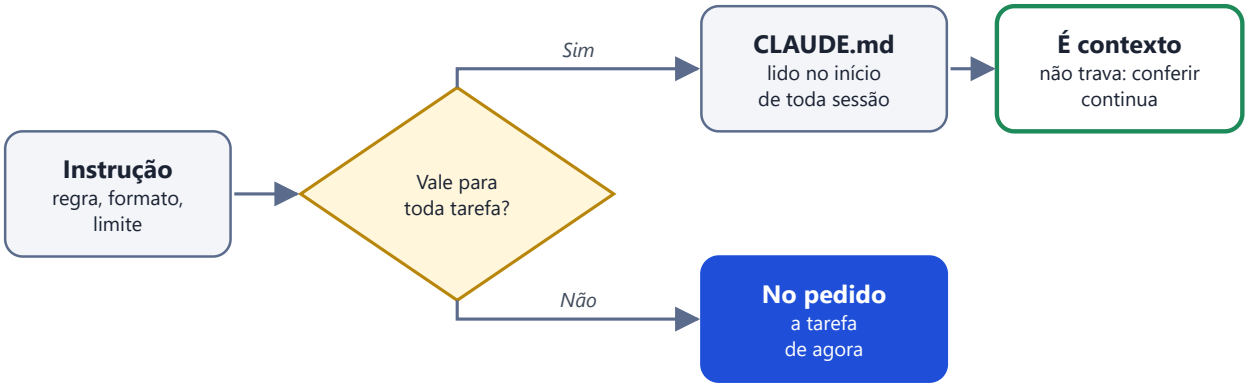
O que vale para toda tarefa vai para o CLAUDE.md

> **O CLAUDE.md é um arquivo na raiz do projeto que o Claude Code lê no início de toda sessão; nele vai o que vale para toda tarefa.**

Parte do que está no F4 vale para qualquer tarefa da Vitrine: regra só vale se estiver escrita, lacuna vira pergunta ao PO, todo resultado esperado aponta a origem. Repetir isso em todo pedido é caro e sujeito a esquecimento; o que precisa durar vai para um arquivo.

O Claude Code carrega o `CLAUDE.md` da raiz do projeto, ou `.claude/CLAUDE.md`, no começo de cada sessão, também no Desktop. Você confere com `/context all`: o arquivo aparece em Memory files. Para cada instrução, uma decisão: vale para toda tarefa? Se vale, vai para o arquivo; se é da tarefa de agora, fica no pedido.

Duas consequências. O arquivo ocupa janela em toda sessão, então precisa ser curto e específico: a documentação recomenda menos de 200 linhas, e no laboratório o limite foi 40. E ele é contexto, não trava: o agente pode deixar de seguir uma instrução. Conferir continua sendo trabalho do QA.



Decisão sobre cada instrução, seja regra, formato ou limite: ela vale para toda tarefa? Se sim, vai para o CLAUDE.md, lido no início de toda sessão; e ele é contexto, não trava, então conferir continua sendo trabalho do QA. Se não, fica no pedido, com a tarefa de agora.

NO CASO VITRINE

No mesmo ensaio, o F1 rodou duas vezes sem e duas com um CLAUDE.md de seis linhas. Sem: 27 e 24 casos, nenhuma coluna de origem. Com: 11 e 10 casos, origem em toda linha, 13 e 10 perguntas ao PO. Uma execução com o arquivo ainda assumiu o motivo obrigatório, remetendo a suposição ao PO.

CONFUSÃO FREQUENTE

Pôr no CLAUDE.md a regra da história em teste, como “o botão aparece em Aguardando pagamento e Pago”. Isso é da tarefa, não do projeto.

PARA CONFERIR · RESPOSTA NO FIM

Como você confirma que o agente leu o seu CLAUDE.md antes de comparar saídas?

Glossário da aula

TERMO	O QUE É
Alucinação	resposta segura e errada: o modelo completa a lacuna com o provável.
Avaliação que só soma acertos	pontuação em que erro e "não sei" valem zero; premia o chute.
Temperatura	ajuste que concentra ou espalha as chances das próximas palavras.
Top-k e top-p	cortes na lista de candidatas: as k mais prováveis, ou as primeiras que somam p.
Variação entre execuções	diferença entre duas respostas ao mesmo pedido, nas mesmas condições.
Formulação	o texto do pedido; no laboratório, do F1 ao F4.
Critério de aceite do pedido	como saber que a resposta do modelo ficou boa.
Pergunta ao PO	lacuna da história registrada como pergunta, em vez de suposição.
Origem	a regra ou o critério de onde vem o resultado esperado, por exemplo US-02 R3.
Sustentado, inferido, inventado	a chave do E1 para classificar cada resultado esperado contra a fonte.
`CLAUDE.md`	instruções do projeto, lidas no início de toda sessão do Claude Code.
`/context all`	mostra o que ocupa a janela; em Memory files, os CLAUDE.md carregados.
Sessão nova	conversa sem o histórico da anterior; no Desktop, **+ New** ou Ctrl+N.
Modo Manual	modo de permissão em que você aprova cada gravação ou comando do agente.

Prática 1 · As formulações em outra história 50 min

Objetivo. Repetir a comparação do laboratório 1 na US-01, com um pedido ingênuo e um especificado, e ver se a diferença entre os pedidos supera a variação entre execuções.

1. Se a pasta já tem o seu `CLAUDE.md` do laboratório 2, renomeie para `CLAUDE.md.off` pelo Explorador de Arquivos ou pelo Finder. Abra uma sessão nova e digite:

   TEXTO PARA O CLAUDE CODE (ABA CODE DO CLAUDE DESKTOP)

   /context all

   EM MEMORY FILES NÃO PODE APARECER O CLAUDE.MD DO PROJETO: ESTA PRÁTICA MEDE SÓ A FORMULAÇÃO.

2. Sem IA, leia `historias/US-01-aplicar-cupom.md` e liste no registro as regras R1 a R6, os critérios CA1 a CA3 e as lacunas que você enxerga. É a sua régua.

3. Pedido ingênuo, numa sessão nova, com o Sonnet 5.5 no seletor:

   TEXTO PARA O CLAUDE CODE (ABA CODE DO CLAUDE DESKTOP)

   Escreva casos de teste para a história historias/US-01-aplicar-cupom.md. Grave a sua resposta completa, sem resumir, em saidas/estudo-US01-ingenuo-a.md.

   REPITA NUMA SEGUNDA SESSÃO NOVA, TROCANDO O FIM DO NOME DO ARQUIVO PARA -B.MD. APROVE SÓ A GRAVAÇÃO EM SAIDAS/.

4. Pedido especificado, também em duas sessões novas:

   TEXTO PARA O CLAUDE CODE (ABA CODE DO CLAUDE DESKTOP)

   Você é analista de QA da Vitrine, uma loja online. Leia historias/US-01-aplicar-cupom.md e o README.md do projeto. Tarefa: escreva os casos de teste funcionais da US-01. Restrições: use apenas as regras (R1 a R6) e os critérios de aceite (CA1 a CA3) escritos na história; quando a história não definir um comportamento, não suponha: registre o ponto como PERGUNTA AO PO; no máximo 12 casos. Faça em três passos e mostre cada um: 1. liste as regras e os critérios de aceite, com o código de cada um; 2. liste as lacunas, cada uma como PERGUNTA AO PO; 3. só então escreva a tabela com as colunas ID, Pré-condição, Ação, Resultado esperado, Origem e Tipo, em que Origem aponta um item do passo 1 e Tipo é positivo, negativo ou borda. Grave a sua resposta completa, sem resumir, em saidas/estudo-US01-especificado-a.md.

   NA SEGUNDA SESSÃO, -B.MD NO FIM. O F3 E O F4 TRAZEM UM EXEMPLO DE LINHA TIRADO DA US-01; POR ISSO ESTE PEDIDO NÃO USA EXEMPLO.

5. Preencha a ficha do laboratório para as quatro saídas: casos, com origem, inventados (sustentado, inferido ou inventado), perguntas ao PO, cobertura dos 9 itens (R1 a R6, CA1 a CA3), aproveitável e minutos de revisão.

6. Compare: a diferença entre as execuções -a e -b do mesmo pedido é menor que a diferença entre os dois pedidos? Escreva a resposta em uma frase. No fim, volte o nome do arquivo para `CLAUDE.md`.

O QUE OBSERVAR

- O tamanho da saída do pedido ingênuo e a quantidade de casos que a história não pede.
- Onde falta a coluna de origem, cada linha custa uma conferência contra a história.
- As contas de desconto: confira cada uma contra a R3, que trata do frete.
- Lacunas marcadas que, mesmo assim, ganharam resultado esperado.

ESTÁ PRONTO QUANDO

Você tem a ficha das quatro saídas e uma frase dizendo se a diferença entre os pedidos supera a diferença entre execuções.

PARA IR ALÉM

Rode o pedido ingênuo de novo, agora com o seu CLAUDE.md de volta na pasta, e veja quanto da distância para o pedido especificado ele fecha.

Prática 2 · Melhore o seu CLAUDE.md e meça de novo

45 min

Objetivo. Transformar os problemas que a ficha do laboratório 2 mostrou em instruções específicas, confirmar o carregamento e medir o F1 outra vez.

1. Reabra a ficha do laboratório 2 (F1 com o seu CLAUDE.md). Marque cada problema que ainda apareceu: caso sem origem, regra inventada, lacuna sem pergunta, formato fora do combinado.

2. Peça uma crítica do arquivo numa sessão nova, sem deixar o agente editar:

   TEXTO PARA O CLAUDE CODE (ABA CODE DO CLAUDE DESKTOP)

   Leia o CLAUDE.md deste projeto e aponte, em no máximo cinco itens, instruções vagas, instruções que só valem para uma história e regras que faltam para casos de teste com origem e perguntas ao PO. Não altere nenhum arquivo.

   SE O AGENTE PEDIR PARA EDITAR O ARQUIVO, REJEITE: QUEM DECIDE CADA LINHA É VOCÊ.

3. Edite o `CLAUDE.md` num editor de texto simples. Para cada problema, uma regra específica em uma linha; corte o que não mudou nada. Até 40 linhas, nada que seja só da US-02.

   NO BLOCO DE NOTAS, SALVE COM O TIPO TODOS OS ARQUIVOS, PARA NÃO VIRAR CLAUDE.MD.TXT. NO TEXTEDIT, USE FORMATAR → CONVERTER EM TEXTO SIMPLES ANTES DE SALVAR.

4. Abra uma sessão nova e confira que a versão nova carregou:

   TEXTO PARA O CLAUDE CODE (ABA CODE DO CLAUDE DESKTOP)

   /context all

   O CLAUDE.MD PRECISA APARECER EM MEMORY FILES. SE NÃO APARECER, ELE NÃO ESTÁ NA JANELA.

5. Rode o F1 em duas sessões novas, uma por execução:

   TEXTO PARA O CLAUDE CODE (ABA CODE DO CLAUDE DESKTOP)

   Leia prompts/formulacoes/F1.md e execute exatamente o pedido escrito nele. Grave a sua resposta completa, sem resumir, em saidas/estudo-F1-claude-md-v2-a.md.

   NA SEGUNDA SESSÃO, -B.MD NO FIM. APROVE SÓ A GRAVAÇÃO EM SAIDAS/.

6. Preencha a mesma ficha e compare com o F1 da primeira versão do arquivo (laboratório 2) e com o F4 sem arquivo (laboratório 1).

O QUE OBSERVAR

- Regra específica muda a ficha; regra vaga não muda nada.
- No ensaio de 12/11, o F1 com um CLAUDE.md de seis linhas citou a origem em toda linha nas duas execuções, e uma delas ainda assumiu que o motivo do cancelamento é obrigatório, remetendo a suposição a uma pergunta ao PO. O arquivo deixa a suposição à vista; não a elimina.
- Se a versão 2 piorou algum número, desfaça a regra que causou isso.

ESTÁ PRONTO QUANDO

Você tem a versão 2 do CLAUDE.md, a confirmação em Memory files e a ficha das duas execuções comparada com a versão 1.

PARA IR ALÉM

Rode o pedido ingênuo da prática 1 (US-01) com a versão 2 e veja se o arquivo vale também para uma história que ele não foi escrito para resolver.

Prática 3 · Revisão com e sem o CLAUDE.md

45 min

Objetivo. Comparar a sua revisão do CT-US01 com a do agente, sem e com as instruções do projeto, e conferir cada apontamento contra a US-01.

1. Sem IA, revise você primeiro: abra `casos-de-teste/CT-US01.md` e `historias/US-01-aplicar-cupom.md` e marque, caso a caso, o que confere, o que está errado e o que falta cobrir. Anote quanto tempo levou.

2. Revisão sem o arquivo: renomeie o `CLAUDE.md` para `CLAUDE.md.off`, abra uma sessão nova, confira com `/context all` que ele não está em Memory files e cole:

   TEXTO PARA O CLAUDE CODE (ABA CODE DO CLAUDE DESKTOP)

   Revise os casos de teste de casos-de-teste/CT-US01.md. Grave a revisão em saidas/estudo-revisao-CT-US01-sem.md.

3. Revisão com o arquivo: volte o nome para `CLAUDE.md`, abra uma sessão nova, confira em Memory files e cole:

   TEXTO PARA O CLAUDE CODE (ABA CODE DO CLAUDE DESKTOP)

   Revise os casos de teste de casos-de-teste/CT-US01.md. Grave a revisão em saidas/estudo-revisao-CT-US01-com.md.

4. Confira cada apontamento das duas revisões contra a US-01 e marque: confere com a história, régua própria do agente ou erro do agente.

   RÉGUA PRÓPRIA É UMA CONTA OU REGRA QUE A HISTÓRIA NÃO USA. NÃO É ALUCINAÇÃO, MAS TAMBÉM NÃO É A HISTÓRIA.

5. Registre em duas listas o que o agente deixou passar e o que você deixou passar no primeiro passo.

O QUE OBSERVAR

- Leia a resposta inteira, não só o resumo do começo. Na revisão registrada no ensaio de 12/11, o resumo inicial e a tabela da mesma resposta discordaram sobre quantos casos estavam corretos.
- Um resultado esperado que contraria a história é o mais caro de deixar passar: o teste aprova o defeito.
- Conte os casos novos que o agente propôs e confira se cada um cita a regra de onde vem.

ESTÁ PRONTO QUANDO

Você tem uma tabela com cada apontamento das duas revisões classificado e uma linha dizendo o que o CLAUDE.md mudou na revisão.

PARA IR ALÉM

Peça, numa sessão nova, os casos do CT-US01 corrigidos com a origem de cada um, e confira as contas de desconto contra a R3 da US-01.

Autoavaliação

Marque o que você já consegue fazer sem consultar o material. O que ficar em branco indica o conceito para reler.

- [ ] Consigo explicar, com a conta 2p − 1, por que uma avaliação que desconta o erro torna o "não sei" vantajoso.
- [ ] Consigo descrever o que a temperatura, o top-k e o top-p fazem no sorteio da próxima palavra.
- [ ] Consigo dizer por que rodo o mesmo pedido duas vezes antes de comparar formulações.
- [ ] Consigo reescrever um pedido ingênuo com papel, contexto, tarefa, restrições e critério de aceite.
- [ ] Consigo dizer o que exemplo, formato fixo e passos mudam no custo da revisão.
- [ ] Consigo decidir, instrução por instrução, o que vai no pedido e o que vai no CLAUDE.md, e confirmar o carregamento com `/context all`.

Respostas das perguntas

1. Se cada erro anulasse um acerto, a partir de que chance de acertar o chute compensa?
Acima de 50%. O valor do chute é p − (1 − p) = 2p − 1, que só fica positivo quando p passa de 0,5.

2. No laboratório, por que o F1 e o F4 rodam duas vezes cada?
Para medir a variação entre execuções do mesmo pedido. Só conta como efeito da formulação a diferença maior que essa variação.

3. Que parte do pedido especificado corresponde ao resultado esperado de um caso de teste?
O critério de aceite: diz como saber que a resposta ficou boa, por exemplo cada regra coberta e cada caso com a origem.

4. Por que o exemplo de linha do F3 vem de outra história?
Para mostrar o formato sem entregar a resposta. Um exemplo da própria US-02 tende a ser copiado como caso.

5. Como você confirma que o agente leu o seu CLAUDE.md antes de comparar saídas?
Numa sessão nova na pasta do caso, `/context all`: o arquivo precisa aparecer em Memory files. Se não aparece, ele não está na janela.

Para ler depois

- Kalai, Nachum, Vempala e Zhang, "Why Language Models Hallucinate", arXiv 2509.04664 (04/09/2025). https://arxiv.org/abs/2509.04664 — por que avaliações que só somam acertos premiam o chute, e a proposta de mudar a pontuação.
- Anthropic, guia de migração da API para a versão 2026-10-21. https://platform.claude.com/docs/en/api/migration-2026-10-21 — temperature, top_p e top_k saem das requisições; do Claude 4.7 em diante, só os valores padrão.

- Anthropic, “Prompting best practices”. https://platform.claude.com/docs/en/build-with-claude/prompt-engineering/claude-prompting-best-practices — clareza, exemplos, estrutura, papel e passos no pedido.
- Claude Code, documentação de memória. https://code.claude.com/docs/en/memory — onde fica o CLAUDE.md, quando ele é carregado e como conferir com /context.
- Claude Code, documentação do Claude Desktop. https://code.claude.com/docs/en/desktop — sessões, seletor de modelo e modos de permissão na aba Code.